


Agente de atención al cliente con RAG, clasificación inteligente de consultas y flujo HITL

1. Diagrama de arquitectura del sistema en [Draw.io](#)

📎 Diagrama entrega final.drawio.png



2. Especificación técnica por capas

Nodo	Componentes n8n	Descripción
1. Ingesta y Triggers	Formulario Mesa de Ayuda Registro de consulta en BD	Captura la entrada del usuario (Nombre , Email , Consulta) mediante un formulario y crea el ticket inicial con estado "nuevo" en la base de datos de Notion .
2. Clasificación de Consultas	Text Classifier Google Gemini Chat Model	Clasifica la consulta en 4 categorías (reclamos , ventas , soporte , otras consultas) utilizando Gemini 3.1 Flash Lite . Define dinámicamente el rol, instrucción y restricciones del prompt.
3. Ingestión RAG (Vector Store)	Notion Get Pages Text Splitter Embeddings Google Gemini Simple Vector Store	Carga las páginas publicadas de la Base de Conocimiento desde Notion . Fragmenta el texto en trozos de 500 caracteres (overlap de 50) y genera embeddings con gemini-embedding-2 guardados en Vector Store en memoria.

4. Agente de IA y Fallback	AI Agent Gemini 3.1 Flash Lite Claude Haiku 4.5 Simple Memory	El AI Agent procesa la consulta con memoria de sesión (Simple Memory). Utiliza Gemini 3.1 Flash Lite como modelo primario y conmuta automáticamente a Claude Haiku 4.5 si el principal falla. Si ambos fallan, dispara una alerta crítica vía Gmail.
5. Enrutamiento y HITL	Switch Gmail sendAndWait If1	Un nodo Switch evalúa la respuesta según 3 reglas: 1. Reclamos: Exige aprobación humana (<i>Human-in-the-Loop</i>) vía email interactivo. 2. Derivación: Si contiene [DERIVAR_SLACK], notifica a la oficina comercial. 3. Directa: Si es consulta regular con respuesta válida, responde directamente.

6. Destino de Datos y Salida	Gmail (Envío)	- Gmail: Envía respuestas finales al cliente.
	Slack (Alertas)	- Slack: Canaliza casos no resueltos a #oficina-reclamos o #oficina_comercial .
	Notion (Actualización)	- Notion: Actualiza el ticket con estado final, categoría asignada y respuesta entregada

3. Matriz de API Keys

- **Notion API:**
 - *Base de datos 1 (Tickets):* Registro inicial y actualización de estado final ([nuevo](#), [Resuelto - Directo IA](#), [Resuelto - Aprobado HITL](#), [Derivado a Slack](#)).
 - *Base de datos 2 (Base de conocimiento):* Lectura de documentos publicados para alimentación RAG.
- **Google AI Studio (Gemini API):**
 - Modelo LLM: [models/gemini-3.1-flash-lite](#) (Clasificación y Agente Principal).
 - Modelo Embeddings: [models/gemini-embedding-2](#) (Indexación y Búsqueda Vectorial).
- **Anthropic API:**
 - Modelo Fallback: [claude-haiku](#) (Respaldo en caso de caída o error en Gemini).
- **Gmail OAuth2:**
 - Envío de mails al cliente.
 - Sistema interactivo de aprobación humana (*sendAndWait*) para supervisión de reclamos.
 - Notificación de errores de ejecuciones al administrador.
- **Slack OAuth2:**
 - Canal [#oficina-reclamos](#) (Casos donde la IA o la propuesta fue rechazada en HITL).
 - Canal [#oficina_comercial](#) (Consultas fuera de la base de conocimiento que requieren derivación humana).

4. Manual operativo de datos

El sistema conecta dos bases de datos en Notion: la **Base de Conocimiento (RAG)** que consulta la IA para responder y la tabla de **Tickets** que registra las consultas.

Resumen de Campos Clave

Base de Datos	Campo	Tipo	Función
Tickets	ID	Texto	Código único (TICK-1042) generado por el sistema.
	Consulta	Texto	Pregunta o reclamo original del cliente.
	Categoría	Selección	Etiqueta asignada por IA (ventas, reclamos, soporte, otras).
	Estado	Selección	Estado operativo (nuevo, Resuelto - Directo IA, Resuelto - Aprobado HITL, Derivado a Slack).
	Respuesta IA	Texto	Respuesta final enviada o propuesta por la IA.
Base de Conocimiento	Estado	Selección	Filtro activo: solo lee registros marcados como Publicado .
	Contenido	Texto	Documentación y normas de la empresa indexadas en el RAG.

[Enlace a Base de Conocimiento Notion](#)

Esquemas JSON

1. Entrada (Formulario)

```
{
  "Nombre": "Agostina Bini",
  "Email": "cliente@ejemplo.com",
  "Consulta": "Quisiera información sobre los paquetes corporativos."
}
```

2. Clasificación y contexto para la IA

```
{
  "ID": "TICK-1042",
  "categoria": "ventas",
  "instruccion": "Rol: Ejecutivo Comercial. Responde solo con información del RAG.",
  "consulta": "Quisiera información sobre los paquetes corporativos."
}
```

3. Salida de la IA y supervisión (HITL)

```
{
  "output": "Estimada Agostina, disponemos del Paquete Corporativo Premium..."
}
```

Si es categoría Reclamo y aprobada por email (HITL)

```
{
  "sendTo": "supervisor@empresa.com",
  "approved": true
}
```

Si requiere derivación a Slack

```
{
  "channel": "#oficina_comercial",
  "text": "🔴 Derivación: El RAG no contiene información sobre descuentos por volumen."
}
```

☆ #oficina_comercial

👤 Invitar a compañeros de equipo 🔊 🔔 🔍 ⋮

🗨 Mensajes 📄 Agregar canvas +

👤 🔴 NUEVA DERIVACIÓN A OFICINA COMERCIAL

Hoy ▾

- Cliente: Agostina Bini
- Email: agosbini@gmail.com
- Consulta del cliente: ¿Tienen disponibilidad y costos para contratar un servicio de catering submarino con chef con estrella Michelin para este fin de semana? 🤖

Respuesta/Análisis de la IA: [DERIVAR_SLACK]

Agradezco tu consulta, pero debo ser transparente contigo: nuestra empresa es una productora de **eventos corporativos y sociales especializada en audiovisuales, sonido e iluminación**.

El servicio de **catering submarino con chef de estrella Michelin** está **fuera de nuestro alcance operativo**. Según nuestra base de datos, trabajamos con proveedores externos de catering, pero no tenemos información específica sobre este tipo de servicio especializado.

B I U 🔗 📌 📋 📄 </> 📎

Mensaje #oficina_comercial

4. Registro final en Notion

```
{
  "pageId": "TICK-1042",
  "properties": {
    "Categoria": "ventas",
    "Estado": "Resuelto - Directo IA",
    "Respuesta IA": "Estimada Agostina, disponemos del Paquete Corporativo Premium..."
  }
}
```

[Enlace a registros en Mesa de Ayuda Notion](#)

Variables utilizadas

Ingesta (Datos del Formulario)

- `{{ $json.Nombre }}`: Nombre completo del cliente que completó el formulario web.
- `{{ $json.Email }}`: Dirección de correo electrónico del cliente para el envío de respuestas o notificaciones.
- `{{ $json.Consulta }}`: Texto original con la duda, solicitud o reclamo ingresado por el usuario.

Identificación

- `{{ $execution.id }}`: Número único asignado por n8n a cada corrida del flujo. Se utiliza para construir el identificador del ticket (ej. `TICK-1042`) y dar seguimiento a los registros.
- `{{ $('Registro de consulta en BD').item.json.property_id }}`: Identificador de la página creada en la base de datos de Notion. Permite ubicar el registro para actualizarlo al final del proceso.

Inteligencia Artificial

- `{{ $json.categoria }}`: Etiqueta asignada por el nodo *Text Classifier* (`ventas`, `reclamos`, `soporte`, `otras consultas`).
- `{{ $json.instruccion }}`: Prompt con el rol, tono y restricciones de negocio que se le inyectan al *AI Agent* según la categoría detectada.
- `{{ $json.output }}`: Respuesta o borrador de correo redactado por el modelo de IA (Gemini / Claude).

HITL y enrutamiento

- `{{ $json.data.approved }}`: Estado devuelto por el nodo interactivo de Gmail (*sendAndWait*). Devuelve **true** si el supervisor aprobó la respuesta de la IA o **false** si la rechazó.
- `{{ $prevNode.name }}`: Nombre del nodo inmediatamente anterior en la ejecución. Permite determinar por cuál rama del diagrama vino la solicitud para definir el valor del campo **Estado final** en Notion (**Resuelto - Directo IA**, **Resuelto - Aprobado HITL**, **Derivado Slack - No resuelto IA**, **Derivado Slack - Rechazado HITL**).

5. Matriz de costos estimados

Tarea	Herramienta elegida	Precio estándar (Sin Caching)	Precio con Prompt Caching (Descuento)	Costo estimado final (por 1.000 consultas)
Leer y analizar consulta + manual (Lectura)	Gemini 3.1 Flash Lite	\$0.075 USD / 1M tokens	\$0.01875 USD / 1M (75% de descuento)	\$0.04 USD (antes \$0.15)
Generar y redactar respuesta (Redacción)	Gemini 3.1 Flash Lite	\$0.300 USD / 1M tokens	N/A (El caché aplica solo a la lectura)	\$0.15 USD
Búsqueda en base de datos (Embeddings)	Gemini Embeddings 2	\$0.020 USD / 1M tokens	N/A (Indexación y búsqueda vectorial)	\$0.02 USD
Plan de respaldo	Claude Haiku	Ent: \$1.00 USD / Sal: \$5.00 USD	Ent. Cacheada: \$0.10 USD / 1M (90% de descuento)	\$0.00 USD (Solo cobra ante fallas)
Registros, Mails y Slack	Notion, Gmail y Slack	N/A (Plataformas integradas)	N/A	\$0.00 USD

- **Costo Total SIN Prompt Caching: \$0.32 USD** por cada 1.000 consultas.
- **Costo Total CON Prompt Caching: \$0.21 USD** por cada 1.000 consultas.
- **Ahorro adicional directo: ~35% de descuento extra** sobre la factura del LLM al mantener en caché las instrucciones fijas del sistema (*System Prompt*) y la Base de Conocimiento de Notion.

[JASON Blueprint](#)

[Video demo 1 - HITL](#)

[Video demo 2 - Derivacion Sack](#)

[Enlace a registros en Mesa de Ayuda Notion](#)

[Enlace a Base de Conocimiento Notion](#)

[Diagrama del flujo](#)